

Задание 2: Подсчет велосипедов

Сайт: [Сервер дистанционного обучения Лаборатории ОИТ](#)

Курс: 2 семестр Анализ данных в Python

Книга: Задание 2: Подсчет велосипедов

Напечатано.: Виталий Евгеньевич Ким

Дата: Thursday, 16 July 2026, 05:38

Оглавление

1. Введение
2. Чтение и обработка данных
3. Исследование и анализ данных

1. Введение

В этом задании мы будем использовать общедоступные данные о подсчете велосипедов в городе Гент (Бельгия). В [Coupure Links](#), рядом с Факультетом инженерии биологических наук, счетчик отслеживает количество проезжающих велосипедистов в обоих направлениях.

```
import pandas as pd
import matplotlib.pyplot as plt
plt.style.use('seaborn-whitegrid')
```

2. Чтение и обработка данных

Чтение CSV-данных

[Данные.](#)

Этот набор данных содержит исторические данные счетчиков велосипедов и состоит из следующих столбцов:

Дата в первом столбце — это дата в формате дд/мм/гг .

Второй столбец tijd — это время суток в формате чч:мм.

Третий и четвертый столбцы ri Centrum и ri Mariakerke — это счетчики на тот момент времени (счетчики между этой отметкой времени и предыдущей).

Обработка данных

Как объяснялось выше, первый и второй столбцы (соответственно datum и tijd) указывают дату и час дня. Чтобы получить временной ряд, мы должны объединить эти два столбца в один ряд фактических значений временных меток.

УПРАЖНЕНИЕ 2

Предварительно обработайте данные:

Объедините столбцы «datum» и «tijd» в одну серию Pandas строковых значений даты и времени, назовите эту новую переменную совмещенной .

Разберите строковые значения даты и времени на объекты даты и времени.

Установите результирующий столбец даты и времени в качестве индекса df DataFrame.

Удалите исходные столбцы «datum» и «tijd», используя метод drop , и вызовите новый кадр данных df2 .

Переименуйте столбцы в DataFrame «ri Centrum», «ri Mariakerke» соответственно. 'direction_centre', 'direction_mariakerke' с использованием метода переименования .

Наличие данных, доступных с интерпретируемым datetime , дает нам возможность иметь график с учетом времени:

```
fig, ax = plt.subplots(figsize=(10, 6))
df.plot(colormap='coolwarm', ax=ax)
```

Когда мы просто хотим интерпретировать даты, не указывая, как даты отформатированы, Pandas пытается сделать это как можно лучше:

```
combined = df['datum'] + ' ' + df['tijd']
```

```
%timeit -n 1 -r 1 pd.to_datetime(combined, dayfirst=True)
```

Однако, когда мы уже знаем формат дат (и если он соответствует всему набору данных), мы можем использовать эту информацию для интерпретации дат:

```
%timeit pd.to_datetime(combined, format="%d/%m/%Y %H:%M")
```

Запишите очистку набора данных как функцию

Чтобы упростить повторное использование кода для предварительной обработки, которую мы реализовали, давайте преобразуем код в функцию Python:

УПРАЖНЕНИЕ 3

Напишите функцию process_bike_count_data(df) , которая выполняет этапы обработки, как описано выше, для входного кадра данных Pandas и возвращает обновленный кадр данных.

```
df_raw = pd.read_csv("data/fietstellingencoupure.csv", sep=';')
df_preprocessed = process_bike_count_data(df_raw)
df_preprocessed.head()
```

Храните наш собранный набор данных в качестве промежуточного продукта данных

Когда мы завершили этап сбора данных, мы хотим сохранить этот результат в качестве промежуточного вывода данных нашего небольшого исследования. Таким образом, нам не нужно повторно загружать все файлы каждый раз, когда что-то пойдет не так, но мы можем начать заново с нашего промежуточного шага.

df_preprocessed.to_csv("bike_count_interim.csv")

3. Исследование и анализ данных

Теперь у нас есть очищенный набор данных о подсчете велосипедов в Coupure Links в Генте (Бельгия). Далее мы хотим получить представление о характеристиках и свойствах данных.

Загрузите промежуточные данные

Чтение файла из промежуточного файла (если вы хотите повторить весь анализ обновленных онлайн-данных, вы должны закомментировать эту ячейку...)

```
df = pd.read_csv("bike_count_interim.csv", index_col=0, parse_dates=True)
```

Проверка интервала подсчета

Количество байкеров подсчитывается с интервалом примерно в 15 минут. Но давайте проверим, так ли это на самом деле. Вычислите разницу между каждым из последовательных значений индекса. Мы можем использовать метод `Series.diff()` :

```
pd.Series(df.index).diff()
```

Представляет интерес количество возможных интервалов:

```
pd.Series(df.index).diff().value_counts()
```

Есть несколько записей, которые не ровно 15 минут. Но, учитывая, что их всего несколько, мы проигнорируем их для текущего тематического исследования и просто сохраним их для этого исследовательского исследования.

```
df.describe()
```

УПРАЖНЕНИЕ 4

Создайте новый ряд Pandas `df_both` , который содержит сумму значений обоих направлений.

УПРАЖНЕНИЕ 5

Используя `df_both` из предыдущего упражнения, создайте новую серию `df_quiet` , содержащую только те интервалы, за которые в сумме в обоих направлениях проехало менее 5 велосипедистов .

УПРАЖНЕНИЕ 6

По исходным данным `df` выбрать только те интервалы, за которые в том или ином направлении проехало менее 3 велосипедистов. Следовательно, менее 3 велосипедистов в сторону центра или менее 3 велосипедистов в сторону Мариакерке.

Считать статистику

УПРАЖНЕНИЕ 7

Какое среднее количество велосипедистов проезжает каждые 15 минут?

УПРАЖНЕНИЕ 8

Какое среднее количество велосипедистов проезжает каждый час?

УПРАЖНЕНИЕ 9

Каковы 10 самых высоких пиковых значений, наблюдаемых в течение любого из интервалов для направления к центру Гента?

УПРАЖНЕНИЕ 10

Какое максимальное количество велосипедистов проехало за один день в обоих направлениях вместе взятых?

Большое количество байкеров, проехавших 05.06.2013, не случайно: http://www.nieuwsblad.be/cnt/dmf20130605_022_-;-)

УПРАЖНЕНИЕ 11

Как выглядит долгосрочный тренд? Рассчитайте ежемесячные суммы и постройте график результата.

УПРАЖНЕНИЕ 12

Давайте посмотрим на некоторые краткосрочные модели. Для данных за первые 3 недели января 2014 г. рассчитайте почасовые подсчеты и визуализируйте их.

Новый год 2013-2014

УПРАЖНЕНИЕ 13

Выберите подмножество набора данных с 2013-12-31 12:00:00 до 2014-01-01 12:00:00 и назначьте результат новой переменной newyear.

Постройте выбранные данные newyear .

Используйте скользящую функцию с окном из 10 значений (см. документацию по функции), чтобы сгладить данные за этот период и построить график сглаженной версии.

Более продвинутое использование Matplotlib для создания комбинированного графика:

Сила groupby ...

Глядя на данные в приведенных выше упражнениях, ясно видно:

ежедневный шаблон

еженедельный шаблон

годовой шаблон

Такие шаблоны можно легко рассчитать и визуализировать в pandas, используя атрибуты DatetimeIndex dayofweek в сочетании с функциональностью groupby . Ниже вкус возможностей, а об этом мы узнаем в следующих блокнотах:

Недельный шаблон :

```
df_daily = df.resample('D').sum()
```

```
df_daily.groupby(df_daily.index.dayofweek).mean().plot(kind = 'bar' )
```

Ежедневный шаблон:

```
df_hourly.groupby(df_hourly.index.hour).mean().plot()
```

Таким образом, дневная картина явно отличается для обоих направлений. Утром больше людей идут на север, вечером больше людей идут на юг. Утренний пик также более сжат.

Ежемесячный шаблон

```
df_monthly = df.resample('M').sum()
```

```
from calendar import month_abbrev
```

```
ax = df_monthly.groupby(df_monthly.index.month).mean().plot()
```

```
ax.set_ylim(0)
```

```
xlabels = ax.set_xticklabels(list(month_abbrev)[0::2])
```